



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

نام و نام خانوادگی : شروین غفاری

موضوع : Hybrid MPSO-CNN

استاد : دکتر قطعی

تدریس‌یار : دکتر یوسفی مهر

گزارش : هفتم

کلمات کلیدی :

1. شبکه عصبی نگاشتی
2. Multiple swarm
3. بهینه سازی Particle swarm
4. MPSO-CNN

چکیده :

الگوریتم PSO برای مسائل بهینه سازی مبتنی بر احتمال در یک فضای جستجو استفاده میشود و این الگوریتم که از طبیعت الهام گرفته شده کاربرد گسترده ای در حل مسائل بهینه سازی در دنیای حقیقی دارد.

با توجه به نوع مسائل میتوان با تغییراتی در این الگوریتم از ویژگی های آن که میتوان به تعداد پارامتر ها و پیچیدگی محاسباتی کم آن اشاره کرد استفاده نمود.

الگوریتم ارائه شده که MPSO نام دارد برای معماری شبکه عصبی نگاشتی (CNN) به منظور بهینه سازی hyperparameter های آن استفاده شده است.

این الگوریتم در مقایسه با یافتن پارامتر های بهینه به شکل manual توسط انسان ها سریعتر بوده و هزینه محاسباتی و overhead کمتری دارد.

الگوریتم MPSO همان PSO اما شامل 2 سطح است که سطح اول آن مربوط ایجاد مجموعه ای از لایه ها و بهینه سازی معماری شبکه است اما سطح دوم آن مربوط به بهینه سازی hyperparameters های لایه هایی است که در سطح اول ایجاد شده اند.

همچنین عملکرد و پیچیدگی الگوریتم MPSO-CNN به بعد فضای جستجو نیز وابسته است.

مقدمه :

برای حل اکثر مسائل در نیای حقیقی غالباً به شبکه های عصبی با بیش از 3 لایه نیاز است که پیچیدگی بالایی دارند و انتخاب hyperparameters به نسبت با افزایش لایه ها دشوار تر میشود .

شبکه های CNN جزو مورد استفاده ترین شبکه ها در deep network ها هستند . الگوریتم هایی که از هوش جمعی استفاده میکنند مانند PSO-ACO و یا الگوریتم ژنتیک کاربرد گسترده ای در چنین شبکه ها دارند اما الگوریتم PSO بیشترین استفاده را به دلیل پارمتر های کم محاسبات ساده و فرموله کردن ساده مسائل دارد.

یکی از نقاط ضعف این الگوریتم همگرایی سریع به جواب های sub-optimal است که با ایجاد تنوع در initialization و یا تنظیم پارمتر ها میتوان این مشکل را برطرف کرد. مدل تغییر یافته آن که در حال حاضر در شبکه CNN به کار برده میشود یک تعادل بین یافتن جواب های جدید و استفاده از جواب های بدست آمده ایجاد کرده و همچنین با اعمال جهش در برخی از particle ها در مراحل میانی این الگوریتم میتوان به همگرایی بهتری دست یافت.

هدف این مقاله استفاده از مدلی از PSO که توانایی یادگیری معماری شبکه را داشته و پارمتر های بهینه مربوط به لایه های آن را به شکل خودکار و بدون دخالت انسان ها پیدا کند.

در گذشته انتخاب پیکربندی مناسب برای شبکه های عصبی نگاشتی بسته به نوع دیتاست نیازمند مهارت گسترده ای بود اما با الگوریتم ارائه شده حتی افراد غیر متخصص نیز میتوانند از این شبکه استفاده کنند.

MPSO سطح اول در فضای جستجو به دنبال مجموعه ای لایه ها برای شبکه و در سطح دوم به دنبال پارمتر هایی با بهترین عملکرد برای هر لایه در سطح اول است. برای ارزیابی هر particle از تابع fitness evaluation که وابسته به CNN بوده استفاده شده اما به دلیل عدم وابستگی particle ها به هم میتوان در مدت زمان مشخص با موازی سازی پارامتر های هر particle را یافت که البته نیازمند سخت افزار قدرتمندی است.

: Convolutional-Neural-Network

یک شبکه عصبی چندلایه بوده که پیچیدگی محاسباتی شبکه های عصبی قدیمی تر را ندارد همچنین به دلیل اینکه بعد فیلتر هایی که روی تصویر ورودی اعمال میشوند نسبت به تصویر ورودی بسیار کمتر است تعداد پارمتر های مورد نیاز برای ارتباط بین خروجی لایه قبل و ورودی لایه بعدی کاهش میابد.

این شبکه شامل 3 نوع لایه بوده که به ترتیب :

1. Convolutional-layer

2. Pooling-layer

3. Fully connected-layer(Dense)

لایه convolutional شامل فیلتر هایی با بعد تعریف شده است که بر روی تصویر ورودی اعمال شده تا feature های آن استخراج شود . اگر چندین مرتبه فیلتر روی تصویر اعمال شود یک feature map ساخته میشود.

لایه Pooling با کاهش دادن بعد بردار های ویژگی خروجی لایه convolutional و حفظ اطلاعات مهم آن محاسبات را کاهش میدهد و Max-Pooling یکی از آنها بوده که بین دو لایه Convolutional قرار میگیرد و برای هر کانال رنگی (color-channel) به طور مستقل عمل میکند. لایه fully connected شامل دو بخش بوده که بخش اول آن برای کاهش بعد بردار خروجی لایه قبل یعنی Pooling layer بوده و بخش دوم آن مربوط به کلاس بندی و label گذاری با تابع softmax می باشد.

مدل پیشنهادی MPSO-CNN :

الگوریتم MPSO شامل چندین swarm بوده که برای بهینه سازی پیکربندی و hyperparameters های شبکه CNN استفاده میشود.

در swarm سطح اول هر particle نشان دهنده یک پیکربندی برای لایه های convolutional, pooling, fully connected و سطح دوم شامل m swarm که هر کدام از n particle تشکیل شده اند. در این سطح هر swarm متناظر با یک particle در سطح اول است.

Particle های هر swarm در سطح دوم شامل filter size, padding size, stride size برای هر کدام از لایه های سطح اول است و این مقادیر ابتدا به صورت تصادفی مقدار دهی شده اند.

در نهایت لایه convolutional بردار ویژگی ها را استخراج کرده و در لایه softmax مقدار accuracy را با تابع fitness که یک particle را به عنوان ورودی دریافت میکند را بر میگرداند.

مقادیر velocity و position برای هر particle در سطح اول و دوم در هر iteration با توجه به p_best و g_best محاسبه شده و درنهایت $[P_i, P_{ij}]$ که P_i نشان دهنده بهینه ترین مقدار برای تعداد لایه های هر کدام از سه نوع لایه گفته شده و P_{ij} نشان دهنده بهینه ترین hyperparameter های مربوط به P_i است.

پیاده سازی الگوریتم :

برای ارزیابی عملکرد الگوریتم از دیتاست MNIST از کتابخانه keras استفاده شده سپس با استفاده از تابع load_data() داده ها را به دو بخش training, test, تقسیم کرده و preprocess را بر روی داده ها انجام میدهیم . سپس در تابع evaluate_fitness پیکربندی CNN را که شامل تعداد لایه های convolutional و pooling و fullyconnected به عنوان ورودی داده و باتوجه به اینکه اعداد به صورت تصادفی بین صفر و یک تولید شده اند آنها را به بازه تعیین شده scale میکنیم.

با دستور Sequential() یک مدل cnn ایجاد کرده و با توجه به تعداد لایه ها با دستور model.add() میتوان لایه مورد نظر را به این شبکه اضافه کرد .

به تعداد لایه های convolutional با دستور conv2D() که تعداد فیلتر ها و سائز فیلتر را به عنوان ورودی دریافت میکند لایه جدید در شبکه قرار میدهیم.

Input_shape() با توجه به width,height,color_channel به صورت پیشفرض (28,28,3) در نظر گرفته شده است.

برای ایجاد لایه Maxpooling که بعد feature map را کاهش میدهد از دستور Maxpooling2D که ورودی آن سایز فیلتر برای pooling را نشان میدهد مقدار دهی میکنیم.

برای تبدیل feature map به یک بردار تک بعدی از Flatten() استفاده میکنیم. درنهایت برای اضافه کردن لایه fullyconnected که بخش اول آن برای کاهش بعد خروجی لایه قبل استفاده شده با دستور Dense که ورودی آن تعداد neuron های این لایه را مشخص میکند و لایه دوم آن که مربوط به کلاس بندی و label زدن است تعداد کلاس های مورد نیاز را به عنوان ورودی دریافت کرده و activation آن را تابع softmax برای انتخاب کلاس ها به شکل احتمالی استفاده میشود.

سپس مدل compile شده و با دستور fit آنرا train میکنیم. برای بدست آوردن دقت بدست آمده با مقادیر داده شده evaluate کرده و accuracy بدست می آید.

: Particle Swarm

برای ایجاد particle یک کلاس ایجاد کرده و به constructor آن محل فعلی particle را داده که pbest نیز به صورت پیشفرض همان در نظر گرفته میشود اما مقدار سرعت را 0 در نظر میگیریم اما fitness در ابتدا مقدار ندارد. ابتدا یک population ایجاد میکنیم که مقادیر ورودی آن Particle با ورودی یک پیکربندی پیشفرض برای CNN است و با تعداد generation های مشخص شده pbest را بر اساس fitness evaluation انتخاب میکنیم که همان دقت cnn برای مقادیر این particle است.

در مرحله بعد gbest انتخاب شده و velocity و position بروزرسانی میشوند. در نهایت میتوان با استفاده از مقادیر gbest بهینه ترین پارمتر های شبکه CNN را انتخاب کرد.

نتایج :

انتخاب پارمتر های بهینه با استفاده از try and error بسیار وقت گیر و نیازمند محاسبات پیچیده هستند اما استفاده از pso که به صورت تصادفی اما هدایت شده عمل میکند میتواند این مسئله را ساده تر کند اما در ابتدا نیازمند تعریف فضای جستجو توسط کاربر می باشد.

محدوده متغیر ها به صورت دستی انتخاب شده و محدوده مجاز برای تغییر مکان particle ها را مشخص میکند.

در ابتدای الگوریتم یک جمعیت اولیه از پیکربندی های ممکن برای شبکه CNN ایجاد کرده و با iteration های بعدی آنرا بهبود میدهیم و الگوریتم به جواب بهینه پس از تعداد متناهی بار همگرا میشود. با افزایش محدوده جستجو پارمتر ها میتوان جواب های بهتری را ایجاد کرد.

نتیجه گیری:

الگوریتم MPSO معرفی شده به دلیل پیاده سازی ساده و تعداد پارامتر های کم آن نسبت به دیگر الگوریتم های تکاملی برای شبکه های عصبی عملکرد قابل قبولی دارد و همانطور که گفته شد این الگوریتم شامل دو سطح بود که سطح اول شامل یک swarm بود که مربوط به پیکربندی شبکه و سطح دوم آن مربوط به انتخاب hyperparameter های بهینه برای لایه های انتخاب شده بود.

نتایج بدست آمده از 5 دیتاست استفاده شده تأییدی بر عملکرد موفق این الگوریتم در انتخاب پارمتر های شبکه CNN بود که به طور خودکار و تصادفی عمل میکرد.

در نهایت میتوان این الگوریتم را با ایجاد تغییراتی در تعداد iteration ها یا اجرای موازی هر کدام از particle ها با توجه به ماهیت مستقل آنها بهبود داد و حتی برای مسائل دیگر به کار گرفت.

منابع :

<https://www.analyticsvidhya.com/blog/2021/08/beginners-guide-to-convolutional-neural-network-with-implementation-in-python/>

<https://towardsdatascience.com/swarm-intelligence-coding-and-visualising-particle-swarm-optimisation-in-python-253e1bd00772>

<https://www.datacamp.com/tutorial/convolutional-neural-networks-python>